


# Rapport d'Évaluation du Modèle

## 1. Méthodologie

Le modèle est une régression logistique (scikit-learn) entraînée sur une représentation TF-IDF (unigrammes et bigrammes) des tweets annotés stockés dans la table MySQL tweets. Chaque tweet est étiqueté positive, negative ou neutral à partir des colonnes binaires positive/negative de la base. Les données ont été séparées en 75% pour l'entraînement et 25% pour la validation, de façon stratifiée afin de conserver la proportion de chaque classe dans les deux sous-ensembles.

## 2. Matrices de Confusion

Deux matrices de confusion binaires ont été calculées sur le jeu de validation : l'une oppose la classe positive au reste (negative + neutral), l'autre oppose la classe negative au reste (positive + neutral), conformément au besoin fonctionnel du cahier des charges.



**Interprétation matrice positive** : sur 32 tweets réellement positifs du jeu de validation, le modèle en retrouve correctement 97% (rappel = 0.97), avec une précision de 0.94 (proportion de prédictions « positive » qui sont correctes). Les erreurs proviennent essentiellement des tweets positifs formulés avec des tournures atténuées ou des négations (« pas mal », « sans être exceptionnel »), moins riches en marqueurs lexicaux positifs explicites.

**Interprétation matrice negative** : sur 32 tweets réellement négatifs, le rappel atteint 0.97 et la précision 0.97. Les confusions résiduelles concernent principalement les tweets sarcastiques (vocabulaire positif utilisé ironiquement, ex. « Génial, encore un retard... »), un cas structurellement difficile pour un modèle « sac de mots » qui ne capture pas le contexte pragmatique de l'énoncé.

### 3. Précision, Rappel et F1-score par Classe

| Classe   | Précision | Rappel | F1-score | Support |
|----------|-----------|--------|----------|---------|
| Positive | 0.94      | 0.97   | 0.95     | 32      |
| Negative | 0.97      | 0.97   | 0.97     | 32      |
| Neutral  | 1.00      | 0.92   | 0.96     | 13      |

- Le F1-score, moyenne harmonique de la précision et du rappel, est équilibré entre les trois classes (entre 0.95 et 0.96), ce qui indique que le modèle ne favorise pas excessivement une classe au détriment d'une autre malgré le léger déséquilibre du jeu de données (davantage de tweets positifs/négatifs que neutres). Ce résultat est en partie dû à l'option *class\_weight = 'balanced'* de scikit-learn, qui pondère automatiquement les classes minoritaires durant l'entraînement.

### 4. Analyse des Performances : Forces, Faiblesses et Biais

#### Forces :

- Le modèle distingue très bien les tweets au vocabulaire de sentiment explicite (adjectifs fortement connotés positivement ou négativement), qui représentent la majorité des cas rencontrés en pratique.
- L'usage de bigrammes dans le TF-IDF permet de capter certaines négations courtes (« pas mal », « pas terrible ») lorsque celles-ci apparaissent suffisamment dans les données d'entraînement.
- La classe neutre est bien identifiée (précision de 1.00), ce qui limite le risque de classer à tort un tweet informatif comme positif ou négatif.

## Faiblesses et biais :

- **Sarcasme et ironie** : les tweets employant un vocabulaire positif dans un sens négatif (« Génial, encore en retard ») sont la principale source d'erreurs. Un modèle « sac de mots » (bag-of-words) pondéré par TF-IDF ne peut pas capturer ce type de contexte pragmatique.
- **Sensibilité à la formulation** : les tweets aux sentiments atténués ou mesurés (« correct sans être exceptionnel ») sont parfois classés en neutre plutôt qu'en positif/négatif, le modèle ayant tendance à sous-pondérer les expressions de sentiment peu marquées.
- **Biais de représentativité du dataset** : le jeu de données d'entraînement actuel est en partie synthétique (généré à partir de modèles de phrases). Il ne reflète qu'imparfaitement la diversité lexicale, les fautes d'orthographe, emojis et abréviations réellement observés sur X. Le modèle risque donc d'être moins performant en production tant qu'il n'aura pas été ré-entraîné sur des données réelles annotées manuellement.
- **Déséquilibre modéré des classes** : la classe neutre est sous-représentée par rapport aux classes positive et négative, ce qui peut, à terme, favoriser légèrement ces deux dernières si le déséquilibre s'accroît avec de nouvelles données.

## 5. Recommandations

1. **Enrichir le dataset avec des données réelles** : collecter et faire annoter manuellement un échantillon de vrais tweets (via l'API X ou un export existant) pour réduire le biais du dataset synthétique actuel.
2. **Traiter explicitement la négation et le sarcasme** : ajouter des features dédiées (détection de négation, ponctuation ironique, majuscules) ou évoluer vers un modèle contextuel (embeddings de type FastText/BERT) capable de mieux capter ces phénomènes.
3. **Suivre le déséquilibre des classes dans le temps** : surveiller la distribution positive/negative/neutral à chaque ré-entraînement hebdomadaire et ajuster `class_weight` ou ré-échantillonner si un déséquilibre important apparaît.
4. **Mettre en place une validation croisée (k-fold)** en plus du split train/validation actuel, pour obtenir une estimation plus robuste des métriques une fois le volume de données réelles suffisant.

**5. Journaliser les prédictions incertaines** (score proche de 0, ou faible marge entre les probabilités des classes) afin de constituer progressivement un jeu de données d'exemples difficiles à ré-annoter en priorité.